

Classificação de tumores cerebrais

Mateus A. Veloso¹, Francisco J. S. Reis², Filipe M. M. Rodrigues³

¹Bacharelado em Sistemas de informação Universidade Federal do Piauí (UFPI)
Campus Senador Helvídio Nunes de Barros
64.607-675 – Picos – PI – Brasil

{mateusveloso, franciscojose17, filipemts, antoniooseas}@ufpi.edu.br

Abstract.

Resumo.

1. Introdução

Sendo a segunda principal causa de morte no mundo, o câncer é uma doença responsável por cerca de 9,6 milhões de óbitos por ano. Ele é caracterizado por um grande grupo de doenças que podem começar em quase qualquer órgão ou tecido do corpo quando as células anormais crescem descontroladamente, vão além de seus limites habituais para invadir outras partes do corpo [Who 2022]. Dentre as formas mais agressivas e letais está o câncer no cérebro, que podem ser divididos em tumores primários, com origem no cérebro e raramente se espalham para outras partes do corpo, e tumores secundários ou metástases, quando o câncer tem origem em outra parte do corpo e se espalha para a cabeça.

Existem mais de 130 tipos diferentes de tumores cerebrais. Os tumores podem começar em qualquer parte do cérebro ou da medula espinhal. Eles são geralmente nomeados de acordo com o tipo de célula a partir do qual se desenvolvem [UK 2022]. Eles são geralmente nomeados de acordo com o tipo de célula a partir do qual se desenvolvem. Eles são agrupados em dois tipos principais, tumores benignos quando o crescimento lento e improvável de se espalhar e tumores malignos, quando o tumor é cancerígeno, sendo capaz de se espalhar para outras partes do cérebro ou da medula espinhal.

A probabilidade de uma pessoa desenvolver esse tipo de tumor durante a vida é inferior a 1%. Os tumores cerebrais representam 85% a 90% de todos os tumores primários do sistema nervoso central (SNC). Em todo o mundo, estima-se que 308.102 pessoas foram diagnosticadas com tumor primário no cérebro ou na medula espinhal em 2020. [Cancer.Net 2022]. Sendo uma doença que pode atingir homens, mulheres e crianças de qualquer idade, origem e classe social. Não discrimina gênero, condição socioeconômica, nacionalidade, idade ou partido político.

Diagnóstico de tumor cerebral envolve uma série de testes e procedimentos, como exames neurológicos, onde será feita uma avaliação da visão, audição, equilíbrio, coordenação, força e reflexos, de modo a se conseguir pistas sobre a parte do cérebro que pode ser afetada por um tumor cerebral. Exames de imagem como ressonância magnética (MRI), tomografia computadorizada, angiograma ou raios-X podem ser usados para identificar o tumor e por último uma biópsia pode ser realizada para determinar se o tumor é cancerígeno ou benigno. Dito isto, este presente trabalho visa desenvolver técnicas de

visão computacional para classificação de tumores cerebrais em imagens de MR, fornecendo assim, uma contribuição valiosa para o processo de automação da classificação de imagens médicas de tumores cerebrais.

2. Metodologia

Esta seção apresenta as etapas envolvidas para para classificação de tumores cerebrais em imagens MRI. Podemos resumir nosso método nas seguintes etapas: i) aquisição de imagens de TB; ii) aplicação de um pré-processamento para destacar os nódulos presentes na imagem; iii) extração de características com objetivo representar, através de valores, as características fundamentais que representam as propriedades contidas nas imagens; iv) classificação das imagens utilizando uma Um multilayer perceptron (MLP); v) avaliamos os resultados alcançados tanto quantitativa quanto qualitativamente. Na Figura 1, apresentamos uma representação gráfica dos passos descritos anteriormente e seguidos pelo método proposto.

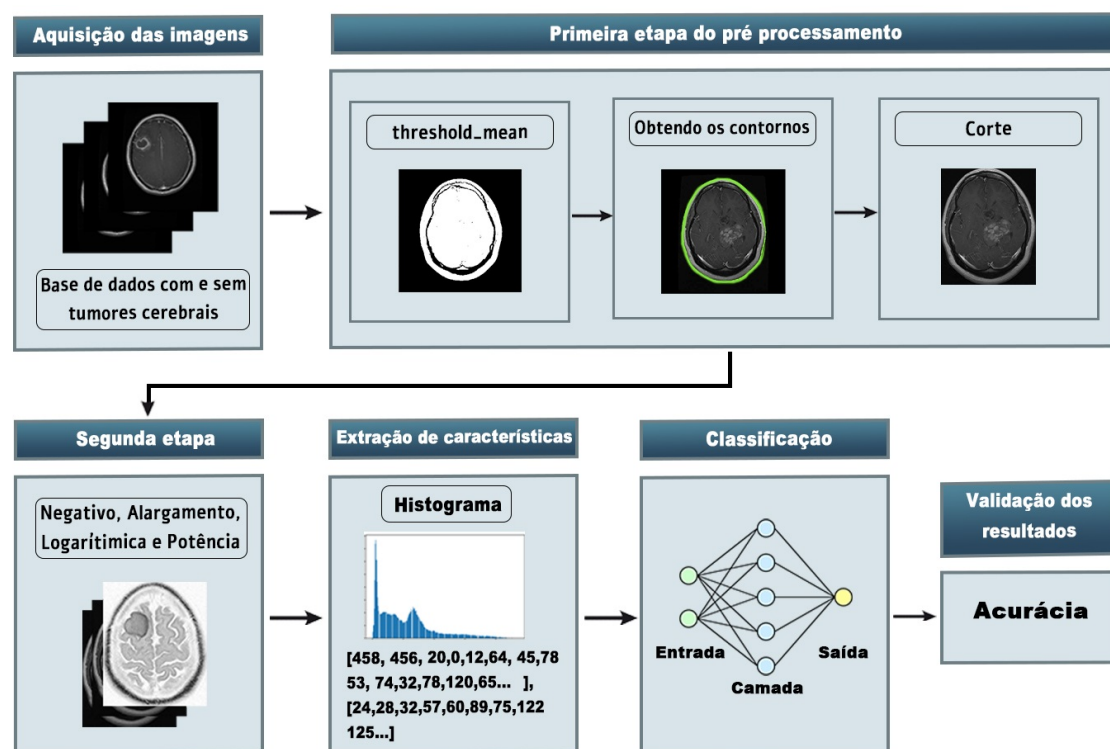


Figura 1. Metodologia

2.1. Aquisição de imagens

O conjunto de imagens de ressonância magnética de tumores cerebrais foi adquirido através da plataforma do Kaggles e inclui quatro classes diferentes: glioma, meningioma, pituitária e sem tumor. Foram obtidas 926 imagens de glioma, 937 imagens de meningioma, 901 imagens de pituitária e 500 imagens sem tumor. As imagens das quatro categorias apresentam diferentes cortes, incluindo axial, coronal e sagital.




Figura 2. Exemplo de uma imagem da classe glioma (corte axial)

2.2. Pré-processamento

Neste trabalho, foi decidido, baseando-se na literatura, utilizar apenas imagens com corte axial. Algumas dessas imagens possuíam áreas indesejáveis, portanto foi necessário realizar cortes nas imagens para remover essas áreas e utilizar apenas as informações úteis. Para isso, adotamos a seguinte metodologia: começamos com a limiarização da imagem; em seguida, encontramos o contorno de maior área, obtendo as coordenadas; finalmente, efetuamos o recorte da imagem com base nas coordenadas obtidas.

Para melhorar a visualização das estruturas específicas das imagens, também foi realizado um pré-processamento de transformação de intensidade. Foram aplicadas quatro funções diferentes: alargamento de contraste, negativo, logarítmico e potência. Todas essas funções foram experimentadas com quatro parametrizações distintas.

2.2.1. Funções de Transformação de Intensidade

Alargamento de contraste: Ela irá aumentar o contraste da imagem se k for maior que r , e diminuir o contraste se k for menor que r . A magnitude do aumento ou diminuição do contraste dependerá do valor de k : quanto maior o valor de k , maior será o aumento ou diminuição do contraste.

$$s = T(r) = 1 / (1 + (k/r)^E)$$

Figura 3. Formula para alargamento de contraste

Negativo: A função negativa inverte os valores de intensidade de cor de cada pixel da imagem. É feito tomando o valor máximo possível de intensidade de cor e subtraindo o valor de intensidade de cada pixel da imagem original.

$$s = L - 1 - r$$

Figura 4. Formula para negativo

Logarítmica: Funciona "expandindo" os valores de intensidade mais baixos e "comprimindo" os valores de intensidade mais altos de forma que a distribuição dos valores de intensidade da imagem se torna mais equilibrada. Isso faz com que as áreas mais escuras de uma imagem sejam mostradas de maneira mais precisa. A constante c é usada para controlar a escala da transformação e é geralmente definida de forma a manter a faixa de valores de intensidade modificada dentro de um limite específico, como o intervalo de 0 a 255 para imagens 8 bits.

$$s = c \log(1 + r)$$

Figura 5. Formula para logarítmica

Potência: Essa função é útil para melhorar a visibilidade de detalhes em uma imagem ou para destacar certas áreas da imagem. À medida que γ é reduzido, mais detalhes se tornam visíveis, diminuindo o contraste e a medida que γ é aumentado melhora o contraste mas áreas muito escuras acaba perdendo detalhe.

$$s = c(r + \epsilon)^\gamma$$

Figura 6. Formula para potência

2.2.2. Extração de características

Para a extração de características, calculamos os histogramas das imagens e posteriormente aplicamos os resultados dos histogramas para calcular os atributos das imagens. Os atributos considerados foram média, variância, skewness, kurtosis, energia e entropia. Uma vez obtidos esses atributos, criamos uma matriz composta por todos os atributos calculados, com uma coluna final que indicava a classe da imagem.

2.2.3. MLP

Na tentativa de imitar o funcionamento do cérebro humano, foram criadas as redes neurais artificiais. Caracterizam como um subconjunto do aprendizado de máquina e estão no centro dos algoritmos de aprendizado profundo. Seu nome e estrutura são inspirados no cérebro humano, imitando a maneira como os neurônios biológicos sinalizam uns aos outros [IBM 2022]. Dentro as inúmeras arquiteturas de redes neurais existentes, a *Multilayer Perceptron (MLP)* é mais encontrada na literatura.

MLPs são uma arquitetura de rede neural composto de neurônios artificiais chamados de perceptron. Que, de modo geral, funcionam com os recursos de entrada passados

para uma função de entrada, que calcula a soma ponderada destes recursos e os envia para uma função de ativação, que determinará se aquela informação é verdadeira ou falsa. Por essa razão, o perceptron é conhecido como um classificador linear, emitindo um para cada ponto entrada acima do hiperplano e zero para cada ponto abaixo dele.

Combinando vários neurônios *MLPs* são capazes de se aproximar tanto de funções contínuas, como de funções lineares. Seus neurônios estão organizados ao longo de mínimo três camadas conforme visto na 7, sendo elas a camada de entrada, que realiza a distribuição dos recursos de entrada para a primeira camada oculta. Às camadas ocultas podem ser um ou varias, a primeira camada oculta recebe como entradas as feições distribuídas pela camada de entrada. As outras camadas ocultas recebem como entrada a saída de cada perceptron da camada anterior [Menzies et al. 2015]. A camada de saída recebe às entradas da camada oculta e retorna um valor.




Figura 7. Arquitetura de uma MLP

Assim, as camadas das *MLPs* adquirem seus dados de recursos das camadas inferiores, desta forma, se todos os pesos no MLP são potencialmente mutáveis, isso significa que por muitas informação que chega a uma determinada camada pode ser não confiável. Como resultado o processo de aprendizado no *MLP* ocorre pela adaptação das conexões pesos a fim de obter uma diferença mínima entre a saída da rede e a saída desejada. Normalmente, utiliza-se o algoritmo de retropropagação baseada em técnicas de gradiente descendente [Ramchoun et al. 2016].

3. Resultados

Esta seção apresenta os resultados alcançados

3.1. Resultados do treinamento

Tabela 1. Resultados obtidos com a imagem original

Pré-processamento	Parâmetros	Acc
Original	-	0.41

Temos na tabela 1 os resultados obtidos com as imagem sem pré-processamento, com uma acurácia de 41%.

Na tabela 2 mostra os resultados obtidos com as imagem obtidas com alargamento de contraste, cuja a melhor acurácia foi com os parâmetros $K=5$ e $E=2$, tendo um acurácia de 36%.

Já na tabela 3 é mostrado os resultados obtidos com as imagens com a transformação de intensidade negativa, que teve uma acurácia de 37%.

Tabela 2. Resultados obtidos com a função de alargamento de contraste

Pré-processamento	Parâmetros	Acc
Alargamento de contraste	K=5 e E=2	0.36
	K=5 e E=3	0.02
	K=5 e E=4	0.03
	K=5 e E=5	0.27
	K=10 e E=2	0.32
	K=15 e E=2	0.23
	K=20 e E=2	0.03

Tabela 3. Resultados obtidos com a função negativa

Pré-processamento	Parâmetros	Acc
Negativo	-	0.37

Tabela 4. Resultados obtidos com a função logarítmica

Pré-processamento	Parâmetros	Acc
Logarítmica	c=0.1	0.36
	c=0.5	0.37
	c=1	0.37
	c=5	0.08

É mostrado na 4 os resultados alcançados com as imagens com função de transformação de intensidade aplicadas, tendo com melhor resultados o parâmetro C =2, com um acurácia de 36%.


Tabela 5. Resultados obtidos com a função potência

Pré-processamento	Parâmetros	Acc
Potência	gamma=0.4	0.21
	gamma=0.6	0.02
	gamma=3	0.03
	gamma=3	0.31
	gamma=5	0.21


Por fim, temos a tabela 4 com resultados com a função de potencia aplicada as imagens com, que obteve o melhor resultado com o parâmetro gamma=0.4, com um acurácia de 21%. Nota-se que conforme o valor de gamma aumenta, o resultado da acurácia diminui.

3.2. Scatter plots

Scatter plots ou gráfico de dispersão usa pontos, ao longo de um plano cartesiano, para representar valores para duas variáveis numéricas diferentes. Desta forma, a posição de cada ponto no eixo vertical e horizontal indica valores para um ponto individual do plano, permitindo assim que observar a relação ou tendência entre variáveis, o que seria impossível de ver em quase qualquer outra forma.




(a) Relação entre variância e entropia.




(b) Relação entre a média e kurtosis.

Figura 8. Resultados do scatter plot.

Na figura 8 o gráfico de dispersão no gráfico 8a podemos ver a correlação entre Variância e entropia, como valores de entropia são geralmente negativos e os de variância muito altos, o plot da correlação dos pontos é quase nula. Na figura 8b temos a correlação dos atributos Kurtosis e Media, como mostra o gráfico eles são atributos que estão bastante correlacionados, não podendo visualizar com exatidão a classe das imagens.



(a) Relação entre a Kurtosi e skewness.



(b) Relação entre skewness e energia.

Figura 9. Resultados do scatter plot.

Já na figura 9 temos o gráfico de dispersão da figura 9a com a correlação entre os atributos Kurtosis e Skewness, que se assemelha a uma reta com concentração com classe sem tumor no começo da reta e a classe pituitary no final. Já na figura 9b a correlação entre Skewness e energia é bastante alta, não sendo possível visualizar nem uma classe de

imagem isolada.

3.3. Redução de dimensionalidade

Redução de Dimensionalidade é uma técnica que visa reduzir variáveis que estão altamente correlacionadas, ou seja que são redundantes, ou em outros casos podemos ter variáveis que não apresentam informações úteis ao problema.




Figura 10. Scatter plot Algoritmo PCA

Na figura 10 é mostrado a redução dos atributos com o algoritmo PCA. Podemos notar que a correlação entre os atributos ainda continua relevante.




Figura 11. Scatter plot Algoritmo TSNE

É mostrado na figura 11 o resultado da redução dos atributos com o algoritmo TSNE. É possível que os atributos encontram-se bem dispersos, ou seja, estão pouco relacionados. Contudo, não é possível visualizar o agrupamento das classes das imagens.




Figura 12. Scatter plot Algoritmo UMAT

Por fim na figura 11 podemos ver o resultado da redução dos atributos com o algoritmo UMAT. Observamos que os atributos reduzidos se agrupam entre dois blocos de classe.

4. Conclusão

Através dos resultados da 3.1, pode-se concluir que os atributos de textura de primeira ordem não são suficientes para representar todas as estruturas e atributos presentes nas imagens de RMI. Mesmo após a aplicação das transformações de intensidade os resultados permanecem insatisfatórios, isso se deve, em parte, ao fato de que as imagens de RMI são imagens de alto contraste. Acreditar-se que técnicas de extração de características mais robustas e modelos de redes neurais mais densos, podem alcançar resultados significativos para a literatura.

Referências

- Cancer.Net (2022). Brain Tumor - Statistics. <https://www.cancer.net/cancer-types/brain-tumor/statistics>. [Online; accessed 2023-01-09].
- IBM (2022). What are Neural Networks? | IBM. <https://www.ibm.com/topics/neural-networks>. [Online; accessed 2023-01-11].
- Menzies, T., Kocagüneli, E., Minku, L., Peters, F., and Turhan, B. (2015). Chapter 24 - using goals in model-based reasoning. In Menzies, T., Kocagüneli, E., Minku, L., Peters, F., and Turhan, B., editors, *Sharing Data and Models in Software Engineering*, pages 321–353. Morgan Kaufmann, Boston.
- Ramchoun, H., Amine, M., Janati Idrissi, M. A., Ghanou, Y., and Ettaouil, M. (2016). Multilayer perceptron: Architecture optimization and training. *International Journal of Interactive Multimedia and Artificial Intelligence*, 4:26–30.
- UK, C. R. (2022). Types of brain tumours | Cancer Research UK. <https://www.cancerresearchuk.org/about-cancer/brain-tumours/types>. [Online; accessed 2023-01-09].

Who (2022). Cancer. https://www.who.int/health-topics/cancertab=tab_1. [Online; accessed 2023-01-09].